

Abstract

- Bert cho bài toán phân loại tài liệu
- trong 1 vài đặc điểm của nhiệm vụ khiến Bert không phải là phù hợp nhất:
 - các cấu trúc cú pháp ít quan trọng hơn đối với các loại nội dung
 - tài liệu thường dài hơn đầu vào thông thường của BERT
 - các tài liệu thường có nhiều nhãn cùng 1 lúc
- tuy nhiên Mô hình phân loại đơn giản sử dụng Bert vẫn có thể đạt SOTA (state of the art) trên 4 bộ dữ liệu phổ biến nhất.
- để giải quyết chi phí tính toán liên quan đến suy luận BERT:
 - Knowledge Distillation – Chắt lọc tri thức
 - từ $BERT_{large}$ thành LSTMs 2 chiều nhỏ hơn (**bidirectional LSTM - BiLSTM**)
=> đạt được tương đương với $BERT_{base}$ trên nhiều bộ dữ liệu nhưng sử dụng ít hơn 30 lần tham số

=> đóng vai trò chính trong bài báo là đưa ra baseline được cải tiến, có thể làm nền tảng cho tương lai

câu hỏi: nếu dùng chuyển từ $BERT_{large}$ về LSTMs nhưng lại có hiệu suất tương đương $BERT_{base}$ thì sao không dùng $BERT_{base}$ luôn

1. Introduction

- gần đây, cách tiếp cận bài toán trong NLP chủ yếu tập chung vào thiết kế kiến trúc neural network sử dụng
 - dữ liệu cho tasks cụ thể
 - word embeddings (GloVe, word2vec, fasttext, ...)
- Tuy nhiên, trong cộng đồng NLP đã có 1 sự thay đổi mang tính bước ngoặt trong tiếp cận mô hình
 - chuyển sang mô hình học sâu sẵn (pre-train model)
 - đạt SOTA trong những tác vụ như:
 - * hỏi đáp
 - * phân tích cảm xúc
- BERT (Bidirectional Encoder representations from transformers) (2019)
 - vượt trội hơn tất cả những thế hệ trước (ELMO, GPT) với khoảng cách lớn trong nhiều tác vụ NLP
 - cách tiếp cận này có 2 giai đoạn:
 - BERT (pre-trained trên lượng lớn văn bản với unsupervised objective)
 - pre-trained network này sau đó được fine-tuned trên những task cụ thể và dữ liệu gán nhãn

=> những Bert chưa được fine-tuned cho document classification

Tại sao điều này đáng được khám phá ?

- **Thứ nhất**, việc mô hình hóa cấu trúc cú pháp được cho là ít quan trọng hơn trong bài toán document classification so với tác vụ thông thường của BERT như:
 - suy luận ngôn ngữ
 - diễn đạt lại câu

=> nhận định này đúng vì mô hình (logistic regression) và SVM là các mô hình baseline đặc biệt mạnh mẽ trong document classification

- **Thứ hai**, documents thường nhiều nhãn và nhiều lớp

Trong paper

- mô tả fine-tuning BERT cho document classification để đạt được kết quả SOTA trên 4 bộ dữ liệu phổ biến
- tuy nhiên tăng chất lượng cho model thì cũng đi kèm với chi phí tính toán cao
 - BERT chứa hàng trăm triệu tham số
 - trong khi baseline trước đó sử dụng ít hơn 4 triệu và thực hiện nhanh hơn gấp 40 lần
- để giảm gánh nặng tính toán:

- áp dụng Knowledge Distillation (Chất lọc tri thức) để chuyển giao kiến thức từ $BERT_{large}$
- biến thể $BERT_{large}$ sang mô hình nhỏ hơn BiLSTM (bidirectional LSTM)

=> đạt được kết quả tương đương được với BERT_base biến thể Bert nhỏ hơn bằng cách sử dụng 1 mô hình ít tham số hơn 30 lần.

Đóng góp trong paper này

- Thiết lập kết quả SOTA cho document classification bằng cách đơn giản là fine-tuned BERT
- BERT có thể chất lọc thành mô hình neural đơn giản hơn nhưng vẫn cung cấp độ chính xác cạnh tranh ở chi phí tính toán khiêm tốn hơn

2. Background and related

- kiến trúc neural network đã chiếm ưu thế trong task of document classification
- Bert tốt những nó có số lượng tham số rất lớn, yêu cầu mức tính toán đáng kể
- Knowledge distillation - KD (chất lọc tri thức)
 - một kỹ thuật nén hiệu quả
 - **chất lọc** thông đã học được từ model lớn (the teacher) sang model nhỏ hơn (the student)
 - sử dụng xác suất phân lớp bởi pre-trained teacher (nhãn mềm - soft targets) để train cho model student trên tập dữ liệu transfer

3. Our approach

- để điều chỉnh $bert_{base}$ và $bert_{large}$ cho document classification
- thêm một tầng fully-connected lên trạng thái ẩn cuối cùng tương ứng với token đầu vào [CLS] (classification token).
- trong quá trình fine-tuning, đã tối ưu toán bộ model từ đầu đến cuối
 - với bộ tham số softmax classifier bổ sung $W \in \mathbb{R}^{K \times H}$
 - * H là kích thước của vector trạng thái ẩn
 - * K là số lượng nhãn (classes)
 - tối thiểu hàm mất mát cross-entropy cho bài toán single-label và hàm mất mát binary cross-entropy cho bài toán multi-label
- tiếp theo, KD từ fine-tuned $bert_{large}$ thành $LSTM_{reg}$ nhỏ hơn nhiều
- thực hiện quá trình (Knowledge Distillation – KD) bằng cách
 - sử dụng các mẫu huấn luyện (training examples)
 - kèm theo một vài phép tăng cường dữ liệu nhỏ (minor augmentations)
 - để tạo thành transfer set.
- kết hợp hai objectives củ classification cho mỗi trong mẫu trong tập chuyển giao (transfer set):
 - $\mathcal{L}_{classification}$ sử dụng target labels để tối ưu hàm mất mát cross-entropy và binary cross-entropy tiêu chuẩn
 - * tùy thuộc vào tập dữ liệu multi-label hoặc single-label
 - $\mathcal{L}_{distill}$ sử dụng soft targets để tối ưu hóa độ chênh lệch Kullback–Leibler (KL)
 - * ký hiệu: $KL(p||q)$
 - p và q là xác suất phân lớp được sinh ra bởi student model và teacher model

Hàm mục tiêu:

$$\mathcal{L} = \mathcal{L}_{classification} + \lambda \mathcal{L}_{distill}(1)$$

trong đó $\lambda \in \mathbb{R}$ là hệ số trọng số dùng để cân bằng mức độ đóng góp của hai hàm mất mát vào mục tiêu huấn luyện tổng thể.

câu hỏi: λ là gì và nếu nó thay đổi thì như thế nào

4. Experimental Setup

- so sánh các mô hình BERT đã fine-tune với các mô hình khác gồm HAN, KimCNN, XMLCNN, SGM, và LSTMreg.

Dataset	C	N	W	S
Reuters	90	10,789	144.3	6.6
AAPD	54	55,840	167.3	1.0
IMDB	10	135,669	393.8	14.4
Yelp 2014	5	1,125,386	148.8	9.1

Table 1: Summary of the datasets. C denotes the number of classes in the dataset, N the number of samples, and W and S the average number of words and sentences per document, respectively.

Figure 1: alt text

- sử dụng GPU Nvidia Tesla V100 và P100 để fine-tune mô hình BERT, và thực hiện các thí nghiệm còn lại trên RTX 2080 Ti và GTX 1080.
- sử dụng PyTorch 0.4.1 làm framework backend, và Scikit-learn 0.19.2 để tính toán các vector tf-idf cũng như triển khai các mô hình Logistic Regression (LR) và Support Vector Machine (SVM).
- lấy ngẫu nhiên 80% dữ liệu để huấn luyện, và 10% cho mỗi phần: xác thực (validation) và kiểm thử (test).

Training and Hyperparameters

1. Khi fine-tuning BERT

đã tối ưu các siêu tham số gồm: + Số epoch (epochs) + Kích thước batch (batch size) + Tốc độ học (learning rate) + Độ dài chuỗi tối đa (Maximum Sequence Length – MSL), + tức là số lượng token tối đa mà mỗi tài liệu sẽ bị cắt ngắn (truncated).

Nhận thấy rằng **chất lượng của mô hình rất nhạy cảm với số lượng epoch**, do đó cần phải điều chỉnh riêng cho từng bộ dữ liệu.

Cụ thể, huấn luyện: + Reuters trong 30 epoch, + AAPD trong 20 epoch, + IMDB trong 4 epoch, và do hạn chế về tài nguyên, chúng tôi chỉ huấn luyện Yelp trong 1 epoch.

Nhận thấy rằng việc chọn kích thước + **batch (batch size)** là 16 + tốc độ học (**learning rate**) là 2×10^{-5} + độ dài chuỗi tối đa (**MSL – Maximum Sequence Length**) là 512 token

=> cho ra hiệu suất tối ưu trên các bộ validation sets.

2. Đối với quá trình distillation

Huấn luyện mô hình $LSTM_{reg}$ để học lại các biểu diễn (representations) đã được học từ $BERT_{large}$, sử dụng hàm mục tiêu được mô tả trong Phương trình (1). + sử dụng kích thước batch là 128 cho các tác vụ (multi-label) + sử dụng kích thước batch là 64 cho các tác vụ (single-label).

Nhận thấy rằng tốc độ học (learning rate) và tỷ lệ dropout được sử dụng trong nghiên cứu của Adhikari et al. (2019) cũng tối ưu cho quá trình distillation này.

Để xây dựng một tập chuyển giao (transfer set) hiệu quả cho quá trình distillation như được đề xuất bởi Hinton et al. (2015), chúng tôi mở rộng (augment) các tập huấn luyện của bộ dữ liệu bằng cách áp dụng: + hoán đổi từ có hướng dẫn theo loại từ (POS-guided word swapping) và + che ngẫu nhiên từ (random masking) (Tang et al., 2019).

Kích thước của tập chuyển giao (transfer set) đối với các bộ dữ liệu Reuters, IMDB và AAPD lần lượt gấp 3 lần, 4 lần, và 4 lần kích thước của tập huấn luyện tương ứng.

Trong khi đó, do hạn chế về tài nguyên tính toán, đối với Yelp 2014, tập chuyển giao chỉ có kích thước bằng đúng (1 lần) tập huấn luyện (tức không áp dụng tăng cường dữ liệu).

Sử dụng giá trị: $+ \lambda = 1$ cho các bộ dữ liệu đa nhãn (multi-label) $+ \lambda = 4$ cho các bộ dữ liệu đơn nhãn (single-label).

5. Results and Discussion

Điểm F1-scores cho các tập dữ liệu đa nhãn và độ chính xác (accuracy) cho các tập dữ liệu đơn nhãn, cùng với độ lệch chuẩn tương ứng, được run năm lần.

#	Model	Reuters		AAPD		IMDB		Yelp '14	
		Val. F ₁	Test F ₁	Val. F ₁	Test F ₁	Val. Acc.	Test Acc.	Val. Acc.	Test Acc.
1	LR	77.0	74.8	67.1	64.9	43.1	43.4	61.1	60.9
2	SVM	89.1	86.1	71.1	69.1	42.5	42.4	59.7	59.6
3	KimCNN Repl.	83.5 $\pm$ 0.4	80.8 $\pm$ 0.3	54.5 $\pm$ 1.4	51.4 $\pm$ 1.3	42.9 $\pm$ 0.3	42.7 $\pm$ 0.4	66.5 $\pm$ 0.1	66.1 $\pm$ 0.6
4	KimCNN Orig.	—	—	—	—	—	37.6 ⁸	—	61.0 ⁸
5	XML-CNN Repl.	88.8 $\pm$ 0.5	86.2 $\pm$ 0.3	70.2 $\pm$ 0.7	68.7 $\pm$ 0.4	—	—	—	—
6	HAN Repl.	87.6 $\pm$ 0.5	85.2 $\pm$ 0.6	70.2 $\pm$ 0.2	68.0 $\pm$ 0.6	51.8 $\pm$ 0.3	51.2 $\pm$ 0.3	68.2 $\pm$ 0.1	67.9 $\pm$ 0.1
7	HAN Orig.	—	—	—	—	—	49.4 ³	—	70.5 ³
8	SGM Orig.	82.5 $\pm$ 0.4	78.8 $\pm$ 0.9	—	71.0 ²	—	—	—	—
9	LSTM _{reg}	89.1 $\pm$ 0.8	87.0 $\pm$ 0.5	73.1 $\pm$ 0.4	70.5 $\pm$ 0.5	53.4 $\pm$ 0.2	52.8 $\pm$ 0.3	69.0 $\pm$ 0.1	68.7 $\pm$ 0.1
10	BERT _{base}	90.5	89.0	75.3	73.4	54.4	54.2	72.1	72.0
11	BERT _{large}	92.3	90.7	76.6	75.2	56.0	55.6	72.6	72.5
12	KD-LSTM _{reg}	91.0 $\pm$ 0.2	88.9 $\pm$ 0.2	75.4 $\pm$ 0.2	72.9 $\pm$ 0.3	54.5 $\pm$ 0.1	53.7 $\pm$ 0.3	69.7 $\pm$ 0.1	69.4 $\pm$ 0.1

Table 2: Results for each model on the validation and test sets. Best values are bolded. *Repl.* reports the mean of five runs from our reimplementations; *Orig.* refers to point estimates from [†]Yang et al. (2018), [‡]Yang et al. (2016), and ^{††}Tang et al. (2015). KD-LSTM_{reg} represents the distilled LSTM_{reg} using the fine-tuned BERT_{large}.




Figure 1: Effectiveness of KD-LSTM_{reg} vs. BERT_{base} and BERT_{large}




Figure 2: alt text

Nhận xét: BERT_{large} đạt được hiệu suất hàng đầu (state-of-the-art) trên cả bốn tập dữ liệu, theo sau là BERT_{base} (hàng 10 và 11). Mô hình LSTM_{reg} (hàng 9), dù đơn giản hơn nhiều, vẫn đạt điểm số cao, gần tiệm cận với chất lượng của BERT_{base}.

Tuy nhiên, cần lưu ý rằng tất cả các mô hình nằm trên hàng 10 chỉ cần một phần nhỏ thời gian và bộ nhớ so với mức yêu cầu để huấn luyện các mô hình BERT.

Đáng ngạc nhiên là distilled LSTM_{reg} (KD-LSTM_{reg}, hàng 12) đạt hiệu suất tương đương với BERT_{base} về trung bình trên các tập dữ liệu Reuters, AAPD và IMDB.

Thực tế, mô hình này thậm chí còn vượt qua $BERT_{base}$ trong ít nhất một trong năm lần chạy.

Đối với Yelp, ta thấy rằng $KD-LSTM_{reg}$ giúp thu hẹp khoảng cách giữa $BERT_{base}$ và $LSTM_{reg}$, nhưng không đáng kể bằng so với các tập dữ liệu còn lại.

Dataset	$LSTM_{reg}$	$BERT_{base}$
Reuters	0.5 (1×)	30.3 (60×)
AAPD	0.3 (1×)	15.8 (50×)
IMDB	6.8 (1×)	243.6 (40×)
Yelp'14	20.6 (1×)	1829.9 (90×)

Table 3: Comparison of inference latencies (seconds) on validation sets with batch size 128.

Để có cái nhìn tổng quan hơn, Bảng 3 trình bày thời gian suy luận (inference time) trên tập xác thực của tất cả các tập dữ liệu.

Chúng tôi tính thời gian suy luận với kích thước batch là 128 cho tất cả các tập dữ liệu, chạy trên một GPU RTX 2080 Ti.

Kết quả cho thấy $KD-LSTM_{reg}$ đạt tốc độ nhanh hơn ít nhất khoảng 40 lần so với $BERT_{base}$.

Ngoài ra, figure 1 trình bày so sánh giữa số lượng tham số và chất lượng dự đoán trên các tập xác thực. Các biểu đồ này cho thấy hiệu quả của mô hình $KD-LSTM_{reg}$ với các số lượng nút ẩn khác nhau: 32, 64, 128, 256 và 512.

Chúng tôi nhận thấy rằng $KD-LSTM_{reg}$ chỉ với 256 nút ẩn (tức khoảng 1% số tham số của $BERT_{base}$) đã đạt hiệu suất tương đương với $BERT_{base}$ trên tập Reuters; trong khi đó, đối với AAPD, 512 nút ẩn (tức khoảng 3% số tham số của $BERT_{base}$) là đủ để vượt qua $BERT_{base}$.

6. Conclusion and Future Work

Trong bài báo này, chúng tôi cải thiện các mô hình chuẩn (baseline) cho bài toán phân loại văn bản bằng cách tinh chỉnh (fine-tune) mô hình BERT. Chúng tôi cũng sử dụng tri thức mà các mô hình BERT đã học được để nâng cao hiệu quả của một mô hình BiLSTM đơn tầng, nhẹ, gọi là LSTMreg, thông qua kỹ thuật tri chứng tri thức (knowledge distillation).

Thực tế, chúng tôi cho thấy rằng mô hình LSTMreg sau khi được distill đạt hiệu năng tương đương với BERTbase trên phần lớn các tập dữ liệu, đồng thời mang lại:

- Giảm hơn 30 lần về số lượng tham số
- Và tốc độ suy luận nhanh hơn ít nhất 40 lần.

For future work

Nghiên cứu trong tương lai có thể tập trung vào việc phân tích tác động của kỹ thuật (knowledge distillation) trên nhiều kiến trúc mạng nơ-ron khác nhau.

Ngoài ra, việc phát triển các kỹ thuật nén mô hình chuyên biệt trong bối cảnh các mô hình transformer cũng là một hướng nghiên cứu đáng được khám phá.